Projet Intégrateur Master DataOps/MLOps

Proposition de sujet : Plateforme de Détection d'Anomalies en Temps Réel pour la Qualité de l'Air (https://explore.openaq.org/locations/3847229)

1. Contexte du Projet

Problématique : Développer une plateforme complète de surveillance de la qualité de l'air qui traite des données de capteurs IoT en streaming, détecte des anomalies, entraîne des modèles prédictifs, et rend les données accessibles via une interface de visualisation et un catalogue.

Objectifs :

- Intégrer DataOps et MLOps dans un scénario réel
- Maîtriser l'orchestration avec Apache Airflow
- Gérer le cycle de vie des modèles avec MLflow
- Traiter des données streaming
- Implémenter un data catalog (optionnel) et des visualisations (Dashbord)

2. Architecture Technique

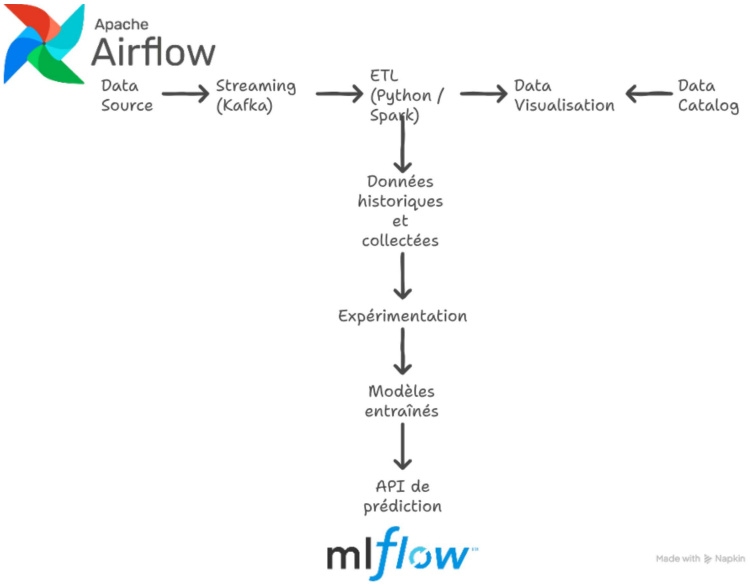

3. Étapes du Projet

Phase 1 : Ingestion et ETL Streaming (2 semaines)

- Outils : Kafka, Spark Structured Streaming/Python, PostgreSQL, MongoDb, ...
- Tâches :

1. Simuler des capteurs IoT (générateur de données Python, ou créer une API qui génère des données en temps réel (comme randomusers.me voir TP)
2. Configurer un cluster Kafka local (3 topics : raw_data, processed_data, anomalies)
3. Développer un consumer Spark/Python pour :

- Nettoyer et valider les données
- Calculer des métriques (moyenne, pics, ...)
- Détecter des anomalies simples (règles métier)

4. Stocker dans PostgreSQL (temps réel + batch quotidien)

Phase 2 : Orchestration avec Airflow (2 semaines)
- Outils : Apache Airflow, Docker
- Tâches :

1. Créer un DAG pour le pipeline quotidien :

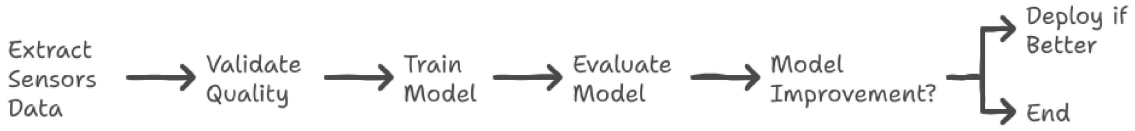

2. Implémenter des capteurs (sensors d'Airflow) pour :
   - Vérifier la disponibilité des nouvelles données
   - Attendre la fin du traitement streaming
3. Créer un DAG pour le backfill (réexécution historique)
4. Configurer les alertes (email/Slack) pour échecs de tâches

Phase 3 : Gestion du Cycle de Vie ML avec MLflow (2 semaines)
- Outils : MLflow, Scikit-learn/XGBoost
- Tâches :

1. Expérimenter avec différents modèles (régression, forêts aléatoires)
2. Suivre les paramètres, métriques et artefacts avec MLflow Tracking
3. Mettre en place MLflow Registry pour :
   - Gérer les versions de modèles
   - Transitions de stage (Staging → Production)
4. Intégrer MLflow avec Airflow (opérateur personnalisé)
5. Créer une API de prédiction avec FastAPI qui utilise le modèle en production.

Phase 4 : Data Catalog et Visualisation (1 semaine)
- Outils : Amundsen (ou alternative simple), Power BI/Tableau/Metabase/superset/...
- Tâches :

1. Déployer Amundsen ou créer un catalogue simplifié (PostgreSQL + interface web)
2. Ingérer automatiquement les métadonnées :
   - Sources de données (capteurs, tables PostgreSQL)
   - Lignée des données (quelle transformation crée quelle table)
   - Métriques de qualité (complétude, fraîcheur)
3. Créer des tableaux de bord pour :
   - Surveillance en temps réel de la qualité de l'air
   - Performance des modèles (dérive, précision)
   - Métriques DataOps (temps de traitement, succès des pipelines)

4. Données et Modélisation

Exemple de Jeu de Données Simulé :

```
{
  "sensor_id": "CAP_001",
  "timestamp": "2024-01-15T14:30:00Z",
  "location": {"lat": 48.8566, "lon": 2.3522},
```

```
  "measurements": {
    "pm2_5": 12.5,  # Particules fines
    "pm10": 25.3,
    "no2": 40.2,    # Dioxyde d'azote
    "o3": 80.1,     # Ozone
    "temperature": 22.5,
    "humidity": 65
  },
  "status": "active"
}
```

Exemples de Problèmes ML à Résoudre :
1. Classification binaire : Anomalie/Normal (supervisé)
2. Prédiction : Niveau de pollution à H+1 (série temporelle)
3. Clustering : Groupement des capteurs par profil

5. Livrables Attendus

Livrable 1 : Code et Infrastructure
- Repository GitHub avec :
  - DAGs Airflow complets
  - Scripts Spark/MLflow
  - Docker-compose pour l'infrastructure
- Documentation d'installation (Readme)
- Communication (ex : Jira ou autres)

Livrable 2 : Rapport Technique (Latex, ex : Overleaf)
- Architecture détaillée
- Choix techniques justifiés
- Métriques de performance (ex : latence, précision, ...)
- Améliorations possibles
- Forme : Page de garde, tables de matière et de figures,style justifier ...

Livrable 3 : Présentation
- Soutenance de 20 minutes
- Démonstration en direct ou Vidéo

Références :

Datasets Réels (en option) :
- OpenAQ (https://openaq.org) - Données qualité air mondiales
- Air Quality Data – UE (https://www.eea.europa.eu/data-and-maps/data/aqereporting-9)

Tutoriels :
- Airflow avec Docker: (https://airflow.apache.org/docs/apache-airflow/stable/howto/docker-compose/index.html)
- MLflow Tutorials (https://mlflow.org/docs/latest/tutorials-and-examples/index.html)
- Spark Structured Streaming (https://spark.apache.org/docs/latest/structured-streaming-programming-guide.html)

Bon courage !